

INFORMACIÓN DEL EQUIPO DE TRABAJO			
MATRÍCULA	NOMBRE (S)	APELLIDOS	GRUPO
233291	Sujey	Calderón Martínez	A
221214	Esduardo	Palomeque Roblero	C
233352	David Reynold	Guzmán Castro	A

INFORMACIÓN DE LA PROPUESTA No. 1 (propuesta principal o con mayor prioridad)		
NOMBRE DEL PROYECTO	Corvus: Aplicación Móvil de Gestión de Memoria Histórica y Auditoría de Proyectos basada en Agrupamiento Vectorial y Procesamiento de Lenguaje Natural.	
CATEGORÍA (marca con una X)	Social	
	Ciencias naturales	
	Ciencias humanas	
	Creativos y culturales	
	Ciencias de la salud	
	Educación y ambientes de aprendizaje	x
PROBLEMÁTICA	Las universidades generan un alto volumen de conocimiento técnico cada cuatrimestre, pero al finalizar el ciclo, esta información queda aislada y "muerta" en carpetas individuales de la nube. Esta desconexión de datos provoca un estancamiento académico: los estudiantes, al carecer de un marco histórico de referencia, proponen ideas repetitivas o recurren a la Inteligencia Artificial de forma deshonestas; mientras que los docentes consumen cientos de horas en tareas burocráticas y auditorías manuales propensas a errores para detectar plagios o recopilar evidencias de acreditación.	
OBJETIVO GENERAL	Desarrollar una aplicación móvil basada en Minería de Datos e Inteligencia Artificial de procesamiento local, diseñada para centralizar el historial de proyectos de la universidad. El sistema automatizará la validación de originalidad analizando los patrones de escritura y metadatos de los alumnos, y fomentará la innovación recomendando áreas temáticas que no han sido exploradas, evitando la repetición de ideas y reduciendo el trabajo manual de revisión de los profesores.	
OBJETIVOS ESPECÍFICOS	1. Ingesta de Datos en Memoria (ETL sin almacenamiento físico): Desarrollar un proceso automático que se conecte a las cuentas de Google Drive mediante su API para leer el contenido de los proyectos pasados como flujo de datos	

(*streaming*). El sistema extraerá el texto en tiempo real sin descargar ni almacenar los archivos PDF físicos en el servidor, protegiendo así el espacio en disco.

2. **Procesamiento y Almacenamiento Vectorial por Referencia:** Procesar los textos extraídos utilizando técnicas de NLP para dividirlos en fragmentos (*chunks*). Estos fragmentos se convertirán a vectores usando el modelo *all-MiniLM-L6-v2* y se guardarán en ChromaDB (base de datos vectorial) únicamente junto con la URL del archivo original. Así, el sistema entiende el contexto y puede auditar documentos manteniendo el repositorio original en la nube de la universidad.
3. **Auditoría de Originalidad (Anti-plagio):** Construir un algoritmo que evalúe las nuevas propuestas calculando matemáticamente la similitud del texto contra el historial de proyectos y cruzando los metadatos del archivo. Esto permitirá detectar de forma automática copias exactas o colisiones entre equipos del mismo semestre, eliminando la revisión manual.
4. **Recomendación de Temas Inexplorados:** Implementar un algoritmo de agrupamiento (*clustering*) en el espacio vectorial. El sistema medirá las distancias de los vectores para identificar las áreas vacías o los puntos más alejados de los clusters densos (temas saturados), traduciendo esos espacios vacíos en sugerencias de proyectos innovadores para los estudiantes.
5. **Formación de Equipos Basada en Evidencia:** Desarrollar un sistema de recomendación que lea el historial de entregas de cada estudiante para deducir sus habilidades técnicas reales de forma automatizada, ayudándoles a formar equipos equilibrados dentro de su mismo grado y grupo.
6. **Simulador de Defensa con LLM Afinado (Fine-Tuning):** Aplicar técnicas de afinamiento eficiente (LoRA/QLoRA) sobre un modelo de lenguaje de tamaño reducido y cuantizado a 4 bits (como *Phi-3 Mini* o *Llama-3 8B*). Este modelo será entrenado específicamente con un corpus de rúbricas y preguntas históricas de los comités evaluadores para que adopte el rol de un "sinodal estricto". Durante la simulación, el modelo analizará el PDF del proyecto y generará preguntas críticas personalizadas en tiempo real, operando de manera fluida sin superar el límite de 8GB de RAM del servidor local.
7. **Desarrollo de la Aplicación Móvil Diferenciada:** Crear las interfaces móviles separando estrictamente la lógica de usuarios:
 - **Para los estudiantes:** Proveer un espacio para validar sus documentos contra el historial, buscar equipo mediante matchmaking y entrenar su defensa.

	• Para los profesores: Construir un panel de control rápido (<i>triage</i>) que reciba alertas automáticas de colisión o plagio y genere un historial de decisiones para respaldar rechazos sin esfuerzo administrativo.
JUSTIFICACIÓN	El problema actual es que los proyectos de cuatrimestres pasados se quedan estancados en el Drive de los profesores. Entonces, los alumnos repiten las mismas ideas y los docentes pierden tiempo auditando posibles copias a mano. Nosotros justificamos este proyecto construyendo un sistema que extrae todo ese historial y lo vuelve información útil. Decidimos procesar todo en un backend local usando modelos cuantizados en lugar de consumir APIs externas por una regla estricta: privacidad de la propiedad intelectual y cero costos operativos. Todo corre <i>on-premise</i>. En cuanto el sistema vectoriza los PDFs, aplicamos algoritmos de <i>clustering</i>. Esto nos sirve para dos cosas principales: primero, detectamos plagios o colisiones matemáticas al instante; y segundo, el sistema busca los espacios vacíos en los vectores para recomendarle a los alumnos temas inexplorados que nadie ha tocado. Al final, el desarrollo de esta plataforma se justifica porque elimina el trabajo burocrático del profesor y obliga a los estudiantes a innovar. Además, aprovechamos esta misma minería para deducir las habilidades reales de cada alumno al armar equipos y los preparamos para su evaluación usando el <i>LLM</i> local, reutilizando el propio conocimiento de la universidad.
USUARIOS FINALES	• Usuario Docente / Coordinador: Es quien tiene el control administrativo. Primero, autoriza la conexión con su cuenta institucional para que el <i>pipeline</i> extraiga los PDFs de su Google Drive. Después de eso, usa su vista en la app para monitorear el avance de sus grupos, recibir las alertas automáticas cuando hay plagio o colisiones entre proyectos, y bloquear temas que ya están saturados para forzar a los alumnos a innovar. • Usuario Estudiante: Es quien interactúa con la plataforma para desarrollar y validar su proyecto. Usa la aplicación para explorar temas nuevos que el sistema le recomienda, armar su equipo mediante el <i>matchmaking</i>, sube su documento para que el algoritmo lo valide, y en cuanto el proyecto está libre de colisiones, entrenar para su exposición final usando el simulador de voz del <i>LLM</i> local.
LISTA DE FUNCIONALIDADES	Funcionalidades del Usuario Estudiante:

POR TIPO DE USUARIO	• Home / Dashboard de Estatus: La pantalla principal donde el alumno ve en qué fase está (buscando equipo, validando documento, o listo para defender). • Explorador de Océanos Azules: Una vista donde el sistema le muestra los temas inexplorados (<i>clusters</i> vacíos) para que elija una ruta de innovación antes de empezar a redactar. • Workspace de Validación (Subida de PDF): La interfaz donde el alumno carga su propuesta. Aquí el sistema corre el <i>pipeline</i> local y le muestra un semáforo de colisión o riesgo de plagio antes de mandarlo al profesor. • Chat de Apelación Restringido: Si el documento no es aceptado, la aplicación no lo bloquea por completo, sino que le abre una ventana de chat directo con el <i>LLM</i>. Para no saturar el servidor, esto está limitado a exactamente dos mensajes por documento subido. En este chat, el alumno puede defender su idea o explicar por qué su proyecto sí es válido, entonces la IA analiza su argumento y le da una retroalimentación más profunda para ayudarlo a corregir el rumbo. • Directorio de Matchmaking Inteligente: Una vista tipo lista donde no solo ven nombres, sino que ven los <i>skills</i> técnicos reales de sus compañeros (extraídos por minería de sus proyectos pasados). • Gestor de Invitaciones: La pantalla para mandar y aceptar solicitudes de equipo. El sistema no te deja armar el equipo si detecta que todos tienen el mismo perfil y les falta, por ejemplo, alguien de <i>backend</i>. • Simulador de Defensa (Interfaz de Voz): La vista donde activan el micrófono. El <i>LLM</i> local afinado actúa como sinodal, lee su documento y les hace preguntas en tiempo real para que practiquen. • Reporte de Retroalimentación de Defensa: Después de usar el simulador de voz, esta vista le genera un resumen al alumno diciéndole en qué preguntas falló o qué partes de su defensa sonaron débiles. • Perfil Técnico Histórico: Donde el alumno puede ver qué habilidades detectó el sistema sobre él basándose en sus PDFs de cuatrimestres anteriores. Funcionalidades del Usuario Docente / Coordinador: • Dashboard de Monitoreo: La pantalla principal del profe donde ve estadísticas rápidas de sus grupos, cuántos equipos ya se formaron y cuántos alumnos siguen sin equipo ("lobos solitarios"). 11. • Centro de Alertas (Triage): Una bandeja de entrada donde caen únicamente los proyectos que el sistema marcó con bandera roja por colisión matemática, copias o discrepancia de estilos. 12.
-----------------------------------	--

	• Vista de Auditoría y Apelaciones: Esta es la contraparte del chat del alumno. Si el documento fue rechazado y el estudiante usó sus dos mensajes para defender su idea con el LLM, el profesor entra a esta vista para leer esa conversación. Aquí evalúa los argumentos que dio el alumno y lee el análisis que hizo la IA sobre esos argumentos; después de eso, el profesor toma la decisión final de aprobar o rechazar la propuesta. 13. • Gestor de Temas (Bloquear): La interfaz donde el docente puede tachar temas que ya están muy repetidos (ej. "sistemas de inventario"). En cuanto bloquea uno, el sistema genera automáticamente las recomendaciones de <i>clusters</i> vacíos para mandárselas a los alumnos. 14. • Historial de Decisiones (Trazabilidad): Una bitácora donde se guardan las justificaciones de la IA y todos los historiales de los chats de apelación. Esto sirve para tener un respaldo directo y auditable por si un alumno se queja al final del cuatrimestre. 15. • Gestor de Conexión ETL (Indexación Cero-Almacenamiento): Una vista de configuración técnica sencilla donde el profesor inicia sesión con OAuth para darle permiso al sistema de leer su Google Drive. El sistema solo extrae y vectoriza el texto en memoria para entrenar a la IA, dejando los archivos físicos intactos en la nube original del profesor para no saturar el servidor local. • Módulo de Reportes CACEI: Una pantalla para exportar las métricas del grupo en formato oficial, mostrando cómo se validó la originalidad y cómo se fomentó la innovación en los proyectos.
LISTA DE TECNOLOGÍAS A APLICAR	Backend Principal: • TypeScript y Node.js: Como el núcleo de nuestro backend. Aquí levantamos el servicio que conecta directamente con la aplicación móvil para manejar los inicios de sesión, la gestión de usuarios y la lógica rápida sin bloqueos. • Google Drive API v3 (OAuth 2.0): Para conectarnos a las carpetas institucionales de los docentes/alumnos y leer los PDFs como un flujo de datos (<i>stream</i>) directo a la memoria RAM. Entonces, en lugar de descargar y guardar el archivo físico en nuestro servidor, la API nos permite extraer el texto en tiempo real, mandarlo al <i>worker</i> de Python para que lo vectoricé y, después de eso, descartar el documento de la memoria. Lo cual garantiza que nuestro disco duro local nunca se sature.

	Microservicio de Inteligencia Artificial: • Python: Aislado en su propio contenedor solo para procesar la carga pesada de IA, comunicándose internamente con el backend de TypeScript. • NLTK y Spacy: Para limpiar y separar en <i>chunks</i> los textos extraídos de los documentos. • PyTorch y PEFT: Para cargar y afinar (<i>fine-tuning</i>) los modelos de lenguaje. • Llama-3 8B (o Phi-3 Mini) cuantizado y all-Mini LM-L6-v2: Los modelos locales que usaremos para el simulador de defensa por voz y para convertir los textos a vectores, procesando todo sin consumir APIs externas. • Scikit-Learn: Para aplicar el algoritmo de <i>clustering</i> matemático y encontrar los espacios vacíos que serán nuestras recomendaciones de temas inexplorados. Bases de Datos y Almacenamiento: • ChromaDB: La base de datos vectorial donde guardamos el contexto semántico de los documentos para la auditoría de originalidad. • PostgreSQL: Para guardar el historial de decisiones, roles, permisos y la trazabilidad de los proyectos. Infraestructura y Despliegue: • Docker y Docker Compose: Para empaquetar todo el ecosistema. Levantaremos contenedores independientes para TypeScript, Python y las bases de datos, asegurando que si un microservicio falla, no tire toda la plataforma. Desarrollo Móvil (Frontend): • Flutter: Para programar la aplicación móvil de cliente ligero y exportar las interfaces para estudiantes y profesores desde un solo código base.
BIBLIOGRAFÍA CONSULTADA	• [Para la parte de Minería y Clasificación] IBM Cloud Education. (2023). <i>¿Qué es la clasificación en el machine learning?</i> IBM Think Topics. https://www.ibm.com/mx-es/think/topics/classification-machine-learning • [Para la justificación del clustering y procesamiento de texto] Joyanes Aguilar, L. (2019). <i>Big Data: Análisis de datos y ciencia de datos en la sociedad de la información</i>. Dialnet. https://dialnet.unirioja.es/download/libro/985766.pdf • [Para la problemática de la educación en línea y gestión de plataformas] Coordinación de Universidad Abierta, Innovación Educativa y Educación a Distancia [CUAIEED]. (2024). <i>Innovación</i>

	<i>educativa y tecnologías para la educación</i>. Universidad Nacional Autónoma de México [UNAM]. https://cuaed.unam.mx/ • [Para el algoritmo de agrupamiento y recomendación semántica] García-Peñalvo, F. J., & Conde-González, M. Á. (2018). Sistemas de soporte a la decisión en el ámbito académico basado en la minería de datos. <i>Education in the Knowledge Society (EKS)</i>, 19(2), 103-126. https://revistas.usal.es/index.php/eks/article/view/eks2018192103126 • [Para la base metodológica de la reutilización de proyectos] Rodríguez-Gómez, D., & Gairín Sallán, J. (2015). <i>La gestión del conocimiento en las instituciones de educación superior: Análisis de la memoria institucional y su impacto académico</i>. Dipòsit Digital de la Universitat de Barcelona. http://hdl.handle.net/2445/19862
--	---